

Proiect de Cercetare Stiințifică: Sistem de detecție și clasificare a interferențelor GNSS

Mircea-Ionuț Meche

January 26, 2026

1 Introducere

Sistemul de Poziționare Globală prin Satelit (GNSS) este vital vieții moderne, fiind folosit în numeroase domenii. Utilizarea sa în spațiul civil și militar îl face susceptibil la interferențe atât naturale, cât și artificiale, iar metodele de atac asupra semnalelor GNSS sunt în continuă dezvoltare. Acest proiect va presupune crearea unei rețele neurale artificiale cu scopul de a detecta și clasifica interferențe în spectrul GNSS. Rețeaua va fi inițial dezvoltată pe baza unei rețele neurale de referință (state-of-the-art) în conformitate cu cercetarea actuală, apoi va fi subdimensionată pentru a putea fi folosită pe un sistem embedded cu capacitate de calcul redusă, în ideea de a avea acest sistem activ pe orice fel de dispozitiv, fiind robust și precis. Pentru desfășurarea lucrării, se vor folosi seturi de date complexe și rețeaua neurală va fi testată folosind atât semnale din seturile de date menționate, dar și semnale generate local cu ajutorul unui dispozitiv radio definit software (SDR) pentru a dovedi practicalitatea sistemului.

2 Arhitectura platformei de dezvoltare

În vederea realizării proiectului, va fi utilizată o platformă de dezvoltare marca NVIDIA Jetson Nano [1]. Această platformă dispune de un procesor grafic care permite execuția în paralel a instrucțiunilor pe segmente relativ mari de date, fiind mult mai eficientă pentru operațiunii de învățare automată în comparație cu o unitate de procesare centrală de tip x86 sau ARM. Procedeele de paralelizare ale datelor și instrucțiunilor sunt garantate de compatibilitatea cu limbajul de programare CUDA [2], care este un limbaj proprietar, disponibil doar pe dispozitivele NVIDIA.

2.1 Specificații

- Procesor grafic generația "Maxwell", 128 de nuclee

- Unitate de procesare centrală ARM Cortex A57
- 4GB RAM LPDDR4
- Gigabit Ethernet
- USB 3.0, USB 2.0, HDMI, MIPI-DSI

3 Structura proiectului

Desfășurarea lucrării va începe atât prin selectarea unei arhitecturi de rețea neurală care să asigure cea mai bună robustețe și acuratețe posibilă, cât prin prelucrarea unor seturi de date de referință. Odată realizată rețeaua neurală de referință, se va face efortul de a optimiza aplicația pentru platforma Jetson prin modificarea hiperparametrilor relevanți.

3.1 Seturile de date

Scopul lucrării este acela de a identifica cu un grad mare de încredere tipul de interferențe GNSS care afectează receptorul, fiind vorba de o problemă de clasificare multi-clasă, accentul fiind atât pe interferențe neintenționate (multipath, efecte atmosferice etc.) cât și pe Interferențe intenționate (jamming, spoofing etc.), cu precădere pe cea de-a doua categorie. Eșantioanele de date extrase din seturi for fi normalizate și procesate, extrăgându-se trăsături specifice semnalelor (frecvența, kurtosis, skewness etc.) care să poată fi pasate mai dreptate rețelei neurale drept trăsături.

În literatura consultată până acum, două seturi de date au fost de interes:

- TEXBAT [3]: Set de date pentru clasificare pentru semnale GPS în benzile L1, L2 și L5 generat de Universitatea din Texas (SUA)
- FGI-OSNMA [4]: Set de date generat de cercetători din Finlanda pentru semnale GALILEO în banda E1B

3.2 Arhitectura sistemului de calcul

În urma cercetării articolelor de specialitate, se constată formarea unor direcții care să fie explorate în această lucrare. Autorii din [5] descriu mai multe metode clasice de mitigare de interferențe, dar subliniază posibilitatea folosirii arhitecturilor clasice (Support Vector Machines - SVM) pentru mitigarea de interferențe multipath, iar autorii articolului [10] menționează rezultatele bune obținute de metodele de învățare automată în ciuda costului computațional. Pe de altă parte, în articolele [6], [8] și [12], cercetătorii folosesc rețele neurale convoluționale (CNN) pentru a putea face clasificarea interferențelor, cu arhitecturi precum MobileNet-v2, AlexNet și ResNet fiind în prim-plan pentru performanțele foarte bune.

În articolul [9], autorii propun folosirea unei rețele neurale adversariale, care să primească concomitent atât eșantioane de semnale GNSS nealterate, cât și interferențe nedorite. Metoda aceasta se remarcă prin fidelitatea față de un caz real, în care receptorul este afectat în timp real. Lucrarea [13] propune mai multe soluții de sisteme de învățare automată, iar autorii din [11] analizează performanțele SVM-urilor și CNN-urilor în condiții de jamming prin clasificare de semnale prelucrate ca imagini.

Prin urmare, am stabilit ca scopul acestei lucrări să ia în considerare parametrii cei mai importanți pentru problema de clasificare și compararea sistemelor clasice de învățare automată cu sisteme mai avansate, iar apoi se va propune un nou model de arhitectură optimizat pentru sisteme integrate. Se va folosi metoda învățării adversariale pentru a putea recrea cât se poate de fidel scenariul real din teren.

4 Concluzie

Dezvoltarea rapidă a receptoarelor GNSS și a tehnicilor de învățare automată pentru dispozitive compacte facilitează existența unei noi generații de receptoare capabile să reziste provocărilor aduse de situația geopolitică actuală, iar scopul acestei lucrări este de a explora aceste noi posibilități în încercarea de a aduce cea mai optimă soluție. Odată realizat, acest proiect poate servi drept baza unui sistem automat nu de detecție, ci de combatere activă a interferențelor malițioase folosind învățarea automată.

5 Bibliografie

- [1] NVIDIA Jetson Nano System-on-Module Datasheet, "https://www.digikey.ro/en/htmldatasheets/production/5264306/0/0/1/dev-16271", accesat la 25.01.2026
- [2] CUDA Toolkit, "https://developer.nvidia.com/cuda/toolkit", accesat la 25.01.2026
- [3] T.E. Humphreys, J.A. Bhatti, D.P. Shepard, and K.D. Wesson, "The Texas Spoofing Test Battery: Toward a Standard for Evaluating GPS Signal Authentication Techniques," Proceedings of ION GNSS, Nashville, TN, 2012
- [4] Liaquat, M.; Bhuiyan, M.Z.H.; Hammarberg, T.; Islam, S.; Saajasto, M.; Kaasalainen, S. An End-To-End Solution Towards Authenticated Positioning Utilizing Open-Source FGI-GSRx and FGI-OSNMA. Eng. Proc. 2025, 88, 58
- [5] J. Zidan, E. I. Adegoke, E. Kampert, S. A. Birrell, C. R. Ford and M. D. Higgins, "GNSS Vulnerabilities and Existing Solutions: A Review of the Literature," in IEEE Access, vol. 9, pp. 153960-153976, 2021
- [6] I. E. Mehr and F. DAVIS, "A Deep Neural Network Approach for Classification of GNSS Interference and Jamming," in IEEE Transactions on Aerospace and Electronic Systems, vol. 61, no. 2, pp. 1660-1676, April 2025

- [7] J. Li, X. Zhu, M. Ouyang, W. Li, Z. Chen and Q. Fu, "GNSS Spoofing Jamming Detection Based on Generative Adversarial Network," in *IEEE Sensors Journal*, vol. 21, no. 20, pp. 22823-22832, 15 Oct.15, 2021
- [8] A. Elango, S. Ujan and L. Ruotsalainen, "Disruptive GNSS Signal detection and classification at different Power levels Using Advanced Deep-Learning Approach," 2022 International Conference on Localization and GNSS (ICL-GNSS), Tampere, Finland, 2022
- [10] Radoš, K.; Brkić, M.; Begušić, D. Recent Advances on Jamming and Spoofing Detection in GNSS. *Sensors* 2024, 24, 4210
- [11] Morales Ferre, R.; de la Fuente, A.; Lohan, E.S. Jammer Classification in GNSS Bands Via Machine Learning Algorithms. *Sensors* 2019, 19, 4841
- [12] N. L. Raichur, T. Brieger, D. Jdidi, T. Feigl, J. R. van der Merwe, B. Ghimire, F. Ott, A. Rügamer, and W. Felber, "Evaluating ML Robustness in GNSS Interference Classification, Characterization and Localization," *arXiv preprint arXiv:2409.15114v1*, Sep. 2024
- [13] van der Merwe, J.R.; Contreras Franco, D.; Hansen, J.; Brieger, T.; Feigl, T.; Ott, F.; Jdidi, D.; Rügamer, A.; Felber, W. Low-Cost COTS GNSS Interference Monitoring, Detection, and Classification System. *Sensors* 2023, 23, 3452